ACTIVITAT AVALUABLE AC4
Mòdul: MÒDUL PROPI **Unitat:** U1 **Professor:** Albert Guardiola **Data límit d'entrega:** 22/09/2026 23:59 **Mètode d'entrega:** Per mitjà del Clickedu de l'assignatura. **S'ha d'entregar un fitxer *MP-AC1_cognom_nom.ipynb***

Resultats de l'aprenentatge:
RA1: Programa pel Big Data a partir de data sources.

Pràctica: neteja, validació i anàlisi de qualitat de dades amb Python

Aquesta pràctica és una **continuació de l'AC3 (Activitat de síntesi 3)** i es basa en els procediments d'exploració, neteja, validació i anàlisi de dades treballats anteriorment.

A l'AC3 has treballat amb un conjunt de dades i has aplicat tècniques de Python per identificar i tractar problemes de qualitat. En aquesta nova pràctica hauràs de reutilitzar i adaptar aquest procediment a un conjunt de dades diferent, corresponent a un sector professional concret.

L'objectiu no és començar de zero, sinó **prendre com a referència el procés d'anàlisi desenvolupat a l'AC3 i adaptar-lo a les característiques del nou conjunt de dades**. Això implica revisar les columnes, identificar-ne els tipus, definir les regles de validació adequades, detectar les incidències, netejar les dades i analitzar els resultats obtinguts.

Els nous fitxers contenen variables diferents de les de l'AC3. Per tant, hauràs d'adaptar el codi i les operacions d'anàlisi al significat de les dades del teu sector. No totes les variables numèriques representen preus o imports: poden correspondre a quantitats, durades, mesures físiques o altres indicadors.

2. Relació amb l'AC3

Per desenvolupar la pràctica, recupera el notebook i el procediment de treball de l'AC3. Utilitza'ls com a guia per dur a terme les fases següents:

1. **Exploració inicial:** carregar el CSV, revisar-ne les columnes i comprendre les dades.
2. **Detecció de problemes:** identificar valors absents, formats incorrectes, valors numèrics invàlids i dates incorrectes.
3. **Neteja i validació:** adaptar les regles de l'AC3 als camps del nou conjunt de dades.
4. **Separació de registres:** obtenir les dades vàlides i identificar les que s'han de rebutjar.
5. **Anàlisi dels resultats:** calcular indicadors, elaborar agrupacions i presentar estadístiques descriptives adequades al sector.
6. **Conclusions:** valorar la qualitat de les dades i interpretar els resultats obtinguts.

La pràctica ha de mostrar que saps **transferir els coneixements adquirits a l'AC3 a un problema nou**, i no només reproduir el codi anterior. Justifica les adaptacions que facis i comprova que les operacions siguin coherents amb el significat de cada variable.

Material de treball

Disposes d'un paquet ZIP que conté **10 fitxers CSV de diferents sectors.** Cada CSV conté registres amb dades correctes i registres amb incidències de qualitat.

Treballaràs amb el fitxer que t'indiqui el professorat o amb el que se t'hagi assignat.

També disposes del notebook `ac3_sol.ipynb`, que pots utilitzar com a punt de partida. Com que els fitxers tenen camps diferents segons el sector, hauràs d'adaptar el codi als noms de columna i als tipus de dades del teu conjunt. No n'hi ha prou amb executar el notebook sense modificar-lo.

La pràctica consta de dues úniques tasques:

Tasca 1. Preparar un notebook de Python (`.ipynb`) amb una anàlisi similar a la de l'AC3

Elabora un notebook que reprodueixi les fases principals de l'anàlisi realitzada a l'AC3, adaptant-les al conjunt de dades assignat.

El notebook ha d'incloure:

1. **Presentació del conjunt de dades:** descripció del sector, objectiu de l'anàlisi i explicació de les columnes.
2. **Exploració inicial:** càrrega del CSV, visualització de les primeres files, dimensions del conjunt de dades i tipus de dades.
3. **Detecció d'incidències:** identificació de camps obligatoris buits, valors numèrics incorrectes, dates invàlides i inconsistències de format.

4. **Neteja i validació:** aplicació de les transformacions necessàries i definició de les regles per determinar quins registres són vàlids.
5. **Gestió dels registres incorrectes:** identificació dels registres rebutjats i explicació dels motius pels quals no es poden acceptar.
6. **Anàlisi de les dades netes:** càlcul d'estadístiques i indicadors rellevants, amb agrupacions per les variables de classificació quan sigui convenient.
7. **Resultats i conclusions:** resum dels principals resultats i valoració de la qualitat de les dades.

El codi de l'AC3 et servirà de referència, però hauràs d'adaptar els noms de les columnes, els tipus de dades, les regles de validació i els càlculs.

Tingues en compte que els camps numèrics de l'AC4 no són necessàriament preus o imports. Poden representar unitats, durades, distàncies, mesures físiques o altres magnituds. Per tant, hauràs de triar operacions i indicadors coherents amb el significat de les variables.

El notebook ha de contenir codi executat, resultats visibles i comentaris que expliquin les decisions principals. Ha de ser ordenat, comprensible i reproduïble.

Tasca 2. Preparar una exposició oral per explicar l'anàlisi

Prepara una exposició per presentar el teu treball i explicar el procés seguit. L'objectiu és demostrar que comprens l'anàlisi i que saps adaptar el procediment de l'AC3 a un conjunt de dades diferent.

L'exposició ha d'incloure els aspectes següents:

1. **Presentació del conjunt de dades**
   - A quin sector pertany?
   - Què representa cada registre?
   - Quines són les columnes principals i què signifiquen?
2. **Relació entre l'AC3 i l'AC4**
   - Quines fases de l'anàlisi de l'AC3 has reutilitzat?
   - Quines parts del codi has pogut mantenir?
   - Quines parts has hagut d'adaptar i per què?
3. **Característiques específiques de les dades**
   - Quines diferències hi ha entre les variables de l'AC3 i les de l'AC4?
   - Quins tipus de dades numèriques hi ha en el nou conjunt?
   - Com han condicionat aquestes diferències les operacions d'anàlisi?
4. **Problemes de qualitat detectats**
   - Quines incidències has identificat?
   - Com les has detectat amb Python?
   - Pots mostrar exemples representatius?
5. **Decisions de neteja i validació**
   - Quines transformacions has aplicat?
   - Quins criteris has utilitzat per acceptar o rebutjar registres?
   - Quines decisions has hagut de modificar respecte de l'AC3?

    - Com has evitat fer correccions arbitràries?
6. **Resultats del procés de neteja**
    - Quants registres hi havia inicialment?
    - Quants s'han acceptat i quants s'han rebutjat?
    - Quines incidències han estat més freqüents?
    - Què indiquen aquests resultats sobre la qualitat de les dades?
7. **Anàlisi de les dades netes**
    - Quins indicadors has calculat i per què?
    - Quines agrupacions o comparacions has fet?
    - Quins resultats consideres més rellevants?
    - Com interpretes les taules o els gràfics que presentes?
8. **Conclusions i possibles millores**
    - Què has après sobre el conjunt de dades?
    - Quines limitacions té l'anàlisi?
    - Quines mesures proposaries per millorar la qualitat de les dades en origen?

Lliurament

Cal lliurar els dos elements següents:

- El notebook de Python (`.ipynb`) amb l'anàlisi completa i executada.
- L'exposició oral preparada a partir del notebook, seguint els aspectes indicats a la tasca 2.

Annex. Presentació dels conjunts de dades

Tots els fitxers contenen camps descriptius o de classificació, dues variables numèriques i una columna de data. Les variables numèriques no tenen necessàriament el mateix significat ni el mateix tipus en tots els fitxers.

1. Botiga d'esports — `01_botiga_esport.csv`

Registra articles d'una botiga d'esports i les seves característiques. Permet estudiar les vendes o els moviments d'articles segons la família esportiva i la botiga.

- **Camps descriptius:** `article`, `familia_esportiva`, `botiga`.
- **Variables numèriques:** `unitats` (nombre enter) i `distancia_km` (valor decimal).
- **Data:** `data`.

L'anàlisi pot comparar les unitats per família esportiva i estudiar els valors de distància registrats.

2. Forn i pastisseria — `02_forn_pastisseria.csv`

Conté registres de productes d'un forn o pastisseria, classificats per família i establiment.

- **Camps descriptius:** `producte`, `familia`, `forn`.
- **Variables numèriques:** `unitats` (nombre enter) i `pes_grams` (valor decimal).
- **Data:** `data`.

Es poden estudiar les unitats registrades per família de producte i resumir el pes dels productes.

3. Clínica veterinària — `03_clinica_veterinaria.csv`

Recull serveis d'una clínica veterinària, amb informació sobre l'espècie atesa i el centre on s'ha registrat l'activitat.

- **Camps descriptius:** `servei`, `especie`, `centre`.
- **Variables numèriques:** `animals_atesos` (nombre enter) i `durada_min` (valor decimal).
- **Data:** `data`.

L'anàlisi pot comparar el nombre d'animals atesos entre espècies o centres i estudiar la durada dels serveis.

4. Taller mecànic — `04_taller_mecanic.csv`

Inclou registres de serveis de taller diferenciats pel tipus de vehicle i l'establiment.

- **Camps descriptius:** `servei`, `tipus_vehicle`, `taller`.

- **Variables numèriques:** `hores_treball` (valor decimal) i `km_vehicle` (nombre enter).
- **Data:** `data`.

Permet estudiar les hores de treball registrades per tipus de vehicle i resumir els quilòmetres associats als registres.

5. Llibreria — `05_llibreria.csv`

Conté informació sobre llibres, el gènere literari i la sucursal en què s'ha registrat cada moviment.

- **Camps descriptius:** `titol`, `genere`, `sucursal`.
- **Variables numèriques:** `exemplars` (nombre enter) i `pagines` (nombre enter).
- **Data:** `data`.

Es poden comparar els exemplars per gènere i analitzar el nombre de pàgines dels llibres registrats.

6. Agència de turisme — `06_agencia_turisme.csv`

Recull activitats turístiques, la seva modalitat i la destinació corresponent.

- **Camps descriptius:** `activitat`, `modalitat`, `destinacio`.
- **Variables numèriques:** `participants` (nombre enter) i `durada_hores` (valor decimal).
- **Data:** `data`.

Permet comparar el nombre de participants per modalitat o destinació i calcular durades mitjanes.

7. Botiga d'electrònica — `07_botiga_electronica.csv`

Registra articles d'electrònica, classificats per família tècnica i botiga.

- **Camps descriptius:** `article`, `familia_tecnica`, `botiga`.
- **Variables numèriques:** `unitats` (nombre enter) i `garantia_meses` (nombre enter).
- **Data:** `data`.

Es poden comparar les unitats registrades per família tècnica i estudiar la durada de les garanties.

8. Gimnàs i fitness — `08_gimnas_fitness.csv`

Conté registres d'activitats físiques, classificades segons el tipus d'activitat i el centre.

- **Camps descriptius:** `activitat`, `tipus_activitat`, `centre`.

- **Variables numèriques:** `participants` (nombre enter) i `durada_min` (valor decimal).
- **Data:** `data`.

Permet comparar la participació per tipus d'activitat i resumir-ne la durada.

9. Floristeria — `09_floristeria.csv`

Recull productes d'una floristeria, classificats pel tipus de planta i la botiga.

- **Camps descriptius:** `producte`, `tipus_planta`, `botiga`.
- **Variables numèriques:** `unitats` (nombre enter) i `alçada_cm` (valor decimal).
- **Data:** `data`.

Es poden analitzar les unitats registrades per tipus de planta i resumir-ne les alçades.

10. Botiga de mobles — `10_botiga_mobles.csv`

Conté registres de mobles, classificats segons el tipus de moble, l'estança a la qual s'associen i la botiga.

- **Camps descriptius:** `moble`, `estança`, `botiga`.
- **Variables numèriques:** `unitats` (nombre enter) i `amplada_cm` (valor decimal).
- **Data:** `data`.

Permet comparar les unitats per estança o tipus de moble i estudiar les amplades registrades.

Recomanació final

Abans de començar, revisa el nom de les columnes i el significat de cada variable del teu fitxer. Les regles de neteja s'han d'adaptar al tipus de dada i al seu significat: una durada, una quantitat d'unitats, una garantia i una mesura física no són variables intercanviables, encara que algunes comparteixin el mateix tipus numèric.